МИНОБРНАУКИ РОССИИ

САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ

ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)

Кафедра МОЭВМ

ОТЧЕТ

по лабораторной работе №5

по дисциплине «Построение и анализ алгоритмов»

Тема: Алгоритм Ахо-Корасик

Студент гр.8304 _____ Мухин А. М.

Преподаватель _____ Размочаева Н.В.

Санкт-Петербург

2020

Цель работы.

Используя реализацию точного множественного поиска, решите задачу точного поиска для одного образца с *джокером*.

Задание.

Вариант 1

На месте джокера может быть любой символ, за исключением заданного.

В шаблоне встречается специальный символ, именуемый джокером (wildcard), который "совпадает" с любым символом. По заданному содержащему шаблоны образцу *P* необходимо найти все вхождения P в текст T.

Например, образец a*b*??c? с джокером ? встречается дважды в тексте *xabvccbababcax*.

Символ джокер не входит в алфавит, символы которого используются в *T*. Каждый джокер соответствует одному символу, а не подстроке неопределённой длины. В шаблон входит хотя бы один символ не джокер, т.е. шаблоны вида ??? недопустимы. Все строки содержат символы из алфавита {*A, C, G, T, N*}.

Описание алгоритма.

Алгоритм строит конечный автомат, которому затем передаёт строку поиска. Автомат получает по очереди все символы строки и переходит по соответствующим рёбрам. Если автомат пришёл в конечное состояние, соответствующая строка словаря присутствует в строке поиска.

Для того чтобы найти все вхождения в текст заданного шаблона с масками Q, необходимо обнаружить вхождения в текст всех его безмасочных кусков. Пусть {Q1,…,Qk} — набор подстрок Q, разделенных масками, и пусть

{l1,…,lk} — их стартовые позиции в Q. Например, шаблон abφφcφ содержит две подстроки без масок ab и cc и их стартовые позиции соответственно 1 и 5.

Для алгоритма понадобится массив C. C[i] — количество встретившихся в тексте безмасочных подстрок шаблона, который начинается в тексте на позиции i. Тогда появление подстроки Q_i в тексте на позиции j будет означать возможное появление шаблона на позиции $j-l_i+1$.

1. Используя алгоритм Ахо-Корасик, находим безмасочные подстроки шаблона Q: когда находим Q_i в тексте T на позиции j, увеличиваем на единицу $C[j-l_i+1]$.
2. Каждое i, для которого C[i] = k, является стартовой позицией появления шаблона Q в тексте.

Вычислительная сложность алгоритма: O(2m + n + a), где n – длинна шаблона, m – длинна текста, a – кол-во появлений подстрок шаблона.

Описание функций и структур данных.

Структура для хранения вершины бора.

```
struct Vertex{
    Vertex(int parent, char symbol, bool is_leaf = false) :
            parent(parent),    symbol(symbol),    is_leaf(is_leaf),
serial_number(-1), suff_link(-1), suff_flink(-1) {}

    int neighbors[5] = {-1, -1, -1, -1, -1};
    int serial_number;
    int suff_link;
    int auto_move[5] = {-1, -1, -1, -1, -1};
    int parent;
    int suff_flink;
    bool is_leaf;
    char symbol;
    std::vector<int> patterns_num{};
};
```

Для структуры бора реализован соответствующий класс.

```
class Bor {
private:
    std::vector<int> start_positions;
    std::map<char, int> alphabet;
    std::vector<Vertex> repository;
    std::vector<std::string> patterns;
    std::string text;
    std::string pattern;
    char joker;
    char unacceptable_symbol;
    std::vector<int> length_vector;

    void add_pattern(const std::string& inserting_string) noexcept;
    [[nodiscard]] int get_suffix_link(const int vertex) noexcept;
    [[nodiscard]] int transition(int vertex, char symbol) noexcept;
    [[nodiscard]] int get_fast_suffix_link(int vertex) noexcept;
    void check(int vertex, int position_in_text) noexcept;

public:
    Bor(std::string& text, std::string& pattern, char& joker, char&
unacceptable_symbol);
    void run(std::ostream& output) noexcept {
        std::string tmp_substring;

        for (int i = 0; i < pattern.size(); ++i) {              //
построение бора из слов,
            if (pattern[i] == joker) {                          // не
содержащих wildcard
                if (!tmp_substring.empty()) {
                    add_pattern(tmp_substring);
                    start_positions.push_back(i                 -
tmp_substring.size());
                    tmp_substring.clear();
                }
```

```
                continue;
            }
            tmp_substring += pattern[i];
        }

        int another_vertex = 0;                                    //
проход по тексту, с фиксированием листов и
        for (int i = 0; i < text.size(); ++i) {                    //
заполнением массива C
            another_vertex       =       transition(another_vertex,
alphabet[text[i]]);
            check(another_vertex, i);
        }

        for (int k = 0; k < length_vector.size(); ++k) {
            if (length_vector[k] == start_positions.size()) {
                bool is_joker = false;
                for (size_t i = k; i < k + pattern.size() - 1; ++i)
{                  // проход по всему шаблону и проверка на
                    if (pattern[i - k] == joker && text[i - 1] ==
unacceptable_symbol){ // то, чтобы джокер в шаблоне не стоял
                        is_joker              =              true;
// на месте запрещённого символа в тексте
                        output  <<  "Find  unacceptable  symbol!"  <<
std::endl;
                        break;
                    }
                }

                if  (!is_joker  &&  k  +  pattern.size()  -  1  <=
text.size())
                    output << "Find match at " << k << " position."
<< std::endl;
            }
        }
    }
```

```
};
```

UML - диаграмма класса представлена ниже:

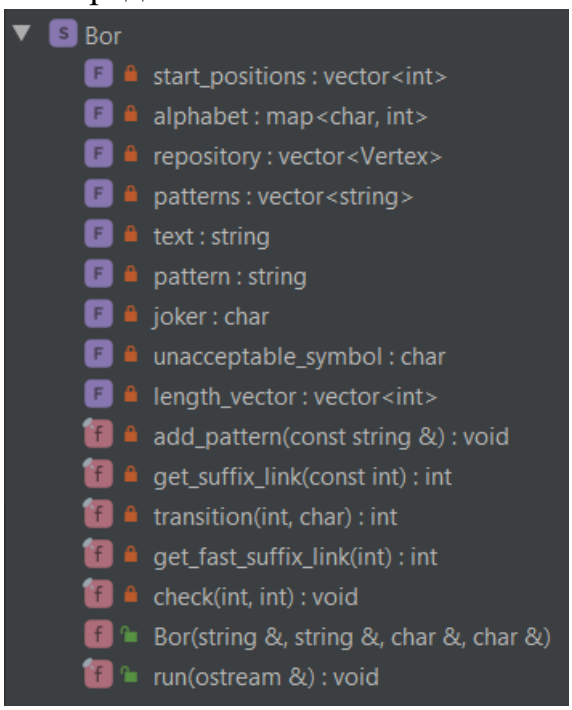

Тестирование

Таблица 1 – результаты тестирования

Input	**Output**
NACGNTTACGGTCACNN AC$$T$AC$$ $ C	2
NACGNTTACGGTCACNN AC$$T$AC$$ $ A	2 8
ACTANCA A$$A$ $ G	1

Выводы.

В ходе выполнения работы, была написана программа, решающая задачу точного поиска для одного образца с джокером с индивидуализацией, чтобы месте джокера мог находится быть любой символ, за исключением заданного.